


Introduction

Depuis 1990, les salariés du secteur privé et public n'ont cessé d'augmenter, tandis que les non-salariés n'ont cessé de diminuer.

Sur la même période, le secteur tertiaire des services a connu un essor au niveau de l'emploi salarié (marchand).

Dans l'édition 2011 de "Emploi et salaires", dans la partie "Les évolutions de l'emploi et des salaires depuis 1990" de l'INSEE, nous y retrouvons ces deux graphiques.



Source : [INSEE](http://www.insee.fr)

Deux observations sont à souligner :

D'une part, l'emploi salarié a connu une hausse entre 1990 et 2008, à la fois dans le secteur privé et dans le secteur public.

D'autre part, l'emploi non-salarié a connu une baisse sur cette même période.

De manière générale, le nombre total de salariés en France a augmenté de 13% entre 1990 et 2008. Notamment, concernant l'emploi salarié, son évolution s'est grandement reposé sur celle du secteur tertiaire des services. En effet, sachant que l'emploi salarié marchand non agricole représentait à peu près 80% de l'emploi salarié, et étant donné la progression de 65% du secteur tertiaire des services, nous en concluons l'importance de cette amélioration dans celle de l'emploi salarié.

En outre, dans cette 11e édition, l'INSEE souligne la "croissance du poids des emplois les plus qualifiés mais aussi de celui des employés non qualifiés" comme facteurs à cette évolution totale des salariés.

Vers les années 1960, le marché du travail était en très bonne santé ; la population active était principalement masculine et peu qualifiée. Le modèle typique des entreprises à cette époque relevait du fordisme et du taylorisme, et les salariés signaient notamment principalement des contrats à durée indéterminée (CDI).

Après les années 1960, deux facteurs ont grandement contribué au développement de la population active en France, et ce jusqu'à la fin des années 1990 : l'insertion des femmes dans le marché du travail et le « baby-boom » ayant suivi la 2nd guerre mondiale.

En d'autres termes, la main-d'œuvre en France a explosé sur cette période, grâce à la montée de l'insertion des femmes dans le marché de l'emploi, mais également grâce à l'arrivée en âge de travailler de la génération « baby-boom ».

Toutefois, la tendance inverse se présente pour les personnes de 15 à 24 ans, soit la part de la population active la plus jeune.

La raison à ce déclin correspond à un niveau de scolarisation plus élevé chez ces derniers.

Ainsi l'écrivent Olivier Marchand et Claude Minni, dans l'article [Les grandes transformations du marché du travail en France depuis le début des années 1960](#) : "L'élévation du niveau général de formation initiale de la population s'est traduit par la hausse de l'âge moyen de fin d'études, passé de 14 ans et demi vers 1960 à plus de 20 ans aujourd'hui (2008)".

Comme le démontre le tableau, ainsi que la figure suivante :

Tableau 1
Contributions de la démographie et des comportements d'activité à la variation de la population active
(moyennes annuelles en %)

	Population active	Effet de la démographie	Effet des taux d'activité				
	Ensemble	Ensemble	Ensemble	15-24 ans	Hommes 25-54 ans	Femmes 25-54 ans	55-69 ans*
1962-1968	+0.7	+1.3	-0.5	-0.2	-0.0	+0.1	-0.4
1968-1975	+1.0	+1.1	-0.1	-0.3	+0.0	+0.6	-0.4
1976-1985	+0.9	+1.0	-0.1	-0.2	-0.0	+0.5	-0.3
1986-1995	+0.5	+0.7	-0.2	-0.5	-0.0	+0.4	-0.0
1996-2008	+0.9	+0.6	+0.4	+0.1	-0.0	+0.2	+0.2
2009-2018	+0.4	-0.1	+0.5	+0.0	-0.1	+0.0	+0.5


* 55 ans ou plus jusqu'en 1975.

Note : la décomposition est réalisée par tranche d'âge quinquennale et par sexe en appliquant aux évolutions annuelles de la population totale le taux d'activité de début de période et aux évolutions annuelles des taux d'activité la population totale de fin de période. Activité déclarée au recensement jusqu'en 1975 ; activité au sens du BIT en moyenne annuelle ensuite. Avant 1976, l'évolution de la population active est mesurée entre les recensements et convertie en moyenne annuelle ; ensuite il s'agit de la moyenne des évolutions annuelles (par exemple pour la période 1976-1985, la moyenne des évolutions annuelles de 1976/1975 jusqu'à 1985/1984).

Note de lecture : de 2009 à 2018, la population active des 15-69 ans s'est accrue de 0.4 % par an : -0.1 % s'explique par l'évolution de la démographie et +0.5 % par l'évolution des taux d'activité.

Champ : France métropolitaine, population de 15 ans ou plus (âge au 31 décembre) jusqu'en 1975, France hors Mayotte, population de 15 à 69 ans (âge exact) à partir de 1975.

Sources : Insee, Recensements de population (1962, 1968, 1975) et séries longues des enquêtes Emploi (à partir de 1975).



Source : [Les grandes transformations du marché du travail en France depuis les années 1960](#)

En ce sens, de 1962 à 2008, la population active des 15-24 ans n'a cessé de diminuer, avec une baisse record de 0.5% par an sur la période 1986-1995.

A première vue, la durée en emploi correspond simplement au temps qu'un individu a passé au travail, soit les années d'expérience de ce dernier.

Toutefois, l'interprétation de la durée en emploi se veut être plus profonde. Elle est le résultat en temps réel des effets de multiples facteurs structurels et conjoncturels, et est notamment le reflet de la santé du marché du travail et de celle de l'éducation.

D'abord, elle traduit les enjeux de la rémunération :

Le salaire, en tant que contrepartie du travail fourni, représente à la fois une source de motivation et un signe de reconnaissance de la valeur de l'employé. Lorsqu'il est jugé satisfaisant, il favorise la fidélité du salarié envers son poste et contribue à prolonger sa présence au sein de l'entreprise. À l'inverse, un salaire trop faible ou perçu comme injuste peut entraîner une perte d'intérêt, voire inciter à chercher de meilleures conditions ailleurs.

Le niveau de rémunération, à priori, influence donc directement la stabilité professionnelle et participe aux mouvements de main-d'œuvre observés sur le marché du travail

Ensuite, il est pertinent de souligner le rôle de l'éducation dans la durée en emploi :

A l'aune de la difficulté accrue de remplacer un individu qualifié par rapport à son homologue peu voire non qualifié, une différence dans la durée en emploi entre ces deux catégories se présente. La qualification d'une personne, en début de carrière, s'exprimant par le biais du niveau d'études de cette dernière, nous pouvons vraisemblablement considérer l'impact non négligeable des études sur la durée en emploi.

Le travail ci-présent porte sur l'enquête "Génération 1998" réalisée par le CEREQ en 2001. Dans cette dernière, le CEREQ a interrogé des milliers d'individus « présumées sorties du système éducatif en 1998-1999 », en 2001, 2003, 2005 et 2008.

En outre, l'échantillon de « 55 000 jeunes » est considéré comme étant « représentatif de l'ensemble des jeunes sortis cette année-là (1998) » ; et ambitionne de suivre les débuts de carrière de ces derniers.

Nous nous proposons d'utiliser les données de cette enquête pour étudier la durée en emploi en France.

Partie 1 statistiques descriptives:

1. description de la base de données:

a. Nombre d'observations

La base de données du CEREQ concernant l'enquête Génération 98" contient au total 5949 observations. Cependant, certaines variables présentent des données manquantes. Par exemple, la variable "age" indiquant l'âge de l'individu au moment de l'enquête ne compte que 5944 observations. De plus, la variable "salcalc", qui correspond au salaire horaire net prime incluse, ne comporte que 5811 observations, soit 135 données manquantes. Cela s'explique probablement par le fait que certaines personnes n'ont pas souhaité répondre à ces questions. Afin de disposer d'un échantillon complet et cohérent, nous avons donc choisi de retenir 5811 observations pour notre analyse.

b. Variable expliquée

La variable que l'on cherche à expliquer est la durée en emploi. Elle est mesurée en mois et concerne les individus sortants de formations initiale en 1998. L'objectif est de comprendre quelles variables influencent cette durée ; autrement dit, ce qui favorise ou non une plus grande durée de l'emploi.

c. Variables explicatives

Pour expliquer cette durée, plusieurs variables explicatives ont été retenues:

- Salcalc ;
- nivagr 1 à 4 ;
- nbent ;
- cspe 1 à 5 ;
- sexe ;
- cens ;
- taille 1 à 4.

Parmi ces 7 variables explicatives, nous en choisissons 2 qui seront des variables d'intérêts

La première est "salcalc", le salaire horaire net prime incluse.

C'est l'une de nos variables d'intérêt, car nous cherchons à savoir si le salaire influence la stabilité de l'emploi. L'hypothèse est qu'un salaire plus élevé encourage les individus à rester plus longtemps dans leur emploi, ce qui devrait donc avoir un effet positif sur la durée en emploi.

La deuxième variable d'intérêt est "nivagr", le niveau d'éducation.

Cette variable prend des valeurs de 1 à 4 : 1 correspond au niveau le plus élevé et 4 au niveau le plus faible. Nous pensons que les personnes ayant un niveau d'éducation plus élevé occupent des emplois demandant plus de qualifications. Par conséquent, cela correspondrait à des meilleurs postes et nous nous attendons à ce que la durée en emploi soit plus longue.

Les autres variables sont considérées comme des variables de contrôle :

La variable "nbent" correspond au nombre d'entreprises par lequel l'individu en question est passé.

Nous pensons que, plus le nombre d'entreprise est grand, plus l'individu a connu des périodes de recherche d'emploi, et moins sa durée en emploi a été longue. Par conséquent, nous nous attendons à une relation négative entre la variable "nbent" et la variable expliquée.

La variable "cspe" indique la catégorie socio-professionnelle au premier emploi.

Elle prend des valeurs entre 1 et 5, chaque nombre correspondant à une classe. Nous pensons que les individus appartenant aux catégories les plus élevées devraient bénéficier d'une plus grande stabilité, ce qui se traduit par une durée en emploi plus longue.

La variable "sexe" distingue les hommes des femmes.

Il est possible que les femmes connaissent plus de discriminations au travail pour diverses raisons et notamment la maternité. Cela a pour cause de créer des interruptions de carrière, réduisant leur durée moyenne en emploi.

La variable "cens" indique si l'individu est encore en emploi au moment de l'enquête.

Nous pensons qu'être encore en emploi montre une plus grande stabilité, et donc une durée en emploi plus longue.

Enfin, la variable "taille" représente la taille de l'entreprise.

Elle prend des valeurs entre 1 et 4 (1 pour les plus petites entreprises et 4 pour les plus grandes).

Nous pensons qu'une plus grande entreprise offre généralement plus de sécurité et de perspectives d'évolution, ce qui devrait avoir un effet positif sur la durée en emploi.

2) Sélection de l'échantillon de travail

Présentation des variables

Voici le tableau de fréquence de la variable “nivagr”:

nivagr	Freq.	Percent	Cum.
Niveau I et II	1,075	18.07	18.07
Niveau III	998	16.78	34.85
Niveau IV	1,345	22.61	57.46
Niveau V	2,150	36.14	93.60
Niveau Vbis et VI	381	6.40	100.00
Total	5,949	100.00	

Il y'a 5949 observation et donc aucune observations manquantes ;

Il n'y a pas de valeurs aberrantes puisque les observations sont regroupées par catégories ;

Le niveau Vbis et VI ne représentant que 6,40% des observations, il sera nécessaire de regrouper cette dernière avec une autre modalité.

Voici le tableau de fréquence de la variable “cspe”:

cspe	Freq.	Percent	Cum.
Employe	2,077	34.91	34.91
ONQ	892	14.99	49.91
OQ	1,013	17.03	66.94
P.lib,cadre,inge,prof.	840	14.12	81.06
Technicien,PI	1,127	18.94	100.00
Total	5,949	100.00	

Au même titre que la variable “nivagr”, il n'y a aucune observations manquantes ni d'observations aberrantes.

Cependant, il n'est ici pas nécessaire de regrouper des modalités entre elles puisqu'elles représentent toutes au moins 10% des observations.

Voici le tableau de fréquence de la variable “taille”:

taille	Freq.	Percent	Cum.
50-500	1,706	28.68	28.68
500 et +	945	15.89	44.56
Nsp	210	3.53	48.09
moins de 10	1,505	25.30	73.39
oct-50	1,583	26.61	100.00
Total	5,949	100.00	

Pareillement, il y’a ici aucune observations manquantes et aucune observations aberrantes. On remarque cependant que la modalité “nsp” qui correspond aux non réponses, ne contient que 3,53% des observations, il sera alors nécessaire de la regrouper avec une autre modalité ou bien de la supprimer.

Voici le tableau de fréquence de la variable “sex”:

sex	Freq.	Percent	Cum.
Femme	2,776	46.66	46.66
Homme	3,173	53.34	100.00
Total	5,949	100.00	

Il y’a ici 5949 observations et donc aucune observations manquantes.

De plus, il y'a aucune observation aberrante car elles sont regroupées par catégories.

Il n’est ici pas nécessaire de regrouper les modalités car elles ne sont que 2 et les regrouper n’aurait donc aucun sens puisque l’on veut analyser l’effet du sexe sur la durée en emploi.

Voici le tableau de fréquence de la variable “cens”:

cens	Freq.	Percent	Cum.
0	1,255	21.10	21.10
1	4,694	78.90	100.00
Total	5,949	100.00	

Pour cette variable, nous pouvons faire les mêmes observations que la variable “sex”, c’est-à-dire, aucune observations manquantes, aucune observations aberrantes et une non nécessité de regroupement des modalités puisqu’il y’en a que 2.

Voici le tableau de distribution de la variable “nbent” :

nbent	Freq.	Percent	Cum.
1	1,762	29.62	29.62
2	1,829	30.74	60.36
3	1,191	20.02	80.38
4	639	10.74	91.12
5	294	4.94	96.07
6	130	2.19	98.25
7	57	0.96	99.21
8	31	0.52	99.73
9	7	0.12	99.85
10	5	0.08	99.93
11	2	0.03	99.97
12	1	0.02	99.98
15	1	0.02	100.00
Total	5,949	100.00	

Il y'a aucune observations manquantes puisqu'il y'en a 5949, et aucune observations aberrantes. Cependant pour les modalités allant de 5 entreprises à 15 entreprises, il y'a une nécessité de regroupement puisqu'elle ne contient que très peu d'observations. En effet, même en additionnant toutes les observations entre 5 et 15, nous n'atteignons à peine 10% des observations. Nous supprimerons aussi les observations "Nsp".


voici le tableau de fréquence de la variable “salcalc”:

Variable	Obs	Mean	Std. dev.	Min	Max
salcalc	5,811	6.772361	3.272971	.4	35.833

Il y'a 5811 observations et donc 138 observations manquantes.

Nous remarquons aussi quelques valeurs aberrantes, notamment les valeurs proches de 0. En effet il s'agit du salaire horaire net et il est très peu probable qu'il soit proche de 0. D'après la description de cette variable donnée par le tableau suivant:

Nous remarquons alors que la plus petite valeur est 0,4, ce qui est impossible.




Voici le tableau de fréquence de la variable “duree”:

Variable	Obs	Mean	Std. dev.	Min	Max
duree	5,949	30.08724	19.71656	1	72

En nous aidant de ce tableau, nous remarquons qu'il y'a 5949 observations et donc aucune observations manquantes.

De plus il y'a aucune observation aberrante puisque les durées sont exprimées en mois, alors la plus petite valeur qui est 1 mois est plausible tout comme la plus grande durée qui est de 72 mois ce qui correspond à 6 ans.



Nettoyage de la base de données

Voici un tableau récapitulant les données manquantes :

. misstable summarize						
Variable	Obs=.	Obs>.	Obs<.	Obs<.		
				Unique values	Min	Max
salcalc	138		5,811	>500	.4	35.833
age	5		5,944	21	26	46

Nous remarquons que la variable "salcalc", qui correspond au salaire horaire net en euros (prime incluse), manque 138 observations; et la variable "age" manque, quant à elle, de 5 observations. Nous décidons alors de poursuivre sans ces individus pour lesquels ces observations sont manquantes.

Au sujet de la variable sur la taille de l'entreprise de l'individu, nous choisissons de retirer les observations "Nsp", soit ceux qui ne connaissent pas la taille de leur entreprise.

Après ces suppressions, la base de données est réduite à 5 606 observations, contre 5 949 observations initialement.

Concernant la variable "salcalc", comme affirmé précédemment, il existe certaines valeurs aberrantes que nous pouvons supprimer. Notamment, nous pouvons supprimer les premier et dernier quantiles, qui pèsent pour 111 observations; la base de données ne compte désormais plus que 5 495 observations.

. su salcalc, detail					. su salcalc, detail				
salcalc					salcalc				
Percentiles		Smallest			Percentiles		Smallest		
1%	1.6	.4	Obs	5,606	1%	2.26	1.6	Obs	5,495
5%	2.5	.49			5%	2.5	1.6		
10%	2.797	.5			10%	2.8	1.603		
25%	5	.5	Sum of wgt.	5,606	25%	5.133	1.633	Sum of wgt.	5,495
50%	6.283		Mean	6.821684	50%	6.283		Mean	6.734635
		Largest	Std. dev.	3.271763			Largest	Std. dev.	2.900187
75%	8.233	27.357	Variance	10.70443	75%	8.229	17.333	Variance	8.411085
90%	10.682	30			90%	10.434	17.333		
95%	13	30.167			95%	12.567	17.333		
99%	17.433	35.833	Kurtosis	7.921268	99%	15.654	17.433	Kurtosis	3.944599

3) Statistiques descriptives univariées-réalisées à partir de l'échantillon de travail

Statistiques univariées sur la variable expliquée "duree"

. tabstat duree, statistics(mean, min, max, p10, p25, p50, p75, p90) col(stat)							
Variable	Mean	Min	Max	p10	p25	p50	p75
duree	30.20783	1	72	6	12	28	47
Variable	p90						
duree	60						

Voici le tableau de statistiques sur la variable expliquée "duree". Dans ce tableau sont représentés :

- la moyenne ,
- la plus petite valeur et la plus grande valeur,
- les quantiles 10%,25%,50%,75% et 90%.


Nous remarquons que, dans l'échantillon, la durée moyenne en emploi dans l'entreprise actuelle de la personne est d'environ 30 mois, soit 2 ans et demi.

Les durées en emploi varient de 1 à 72 mois (6 ans).


10% des personnes interrogées présentent un niveau d'ancienneté inférieur ou égal à 6 mois dans leur entreprise, au moment de l'enquête.

50% des personnes interrogées ont un niveau d'ancienneté inférieure ou égal à 2 ans et 4 mois dans leur entreprise, au moment de l'enquête.

De manière plus générale, la grande majorité des personnes interrogées affirment une durée en emploi de moins de 5 ans dans leur entreprise, au moment de l'enquête ; et un dixième de l'échantillon affirme être resté en emploi dans leur entreprise pendant plus de 5 ans.



Le graphique ci-dessus représente la distribution brute de la variable expliquée "duree".
 Les observations des différentes durées en emploi témoignent d'une certaine uniformité, malgré une plus grande concentration pour les durées inférieures à 18 mois (1 an et demi) et une faible représentation des durées supérieures à 66 mois (5 ans et demi).



Nous proposons le graphique brut de la variable "ln_duree", qui correspond à la version logarithmique de la variable expliquée "duree".


Le graphique associé à la variable "ln_duree" présente une tendance haussière (et la majeure partie des observations se situe entre ln_duree = 2 et ln_duree = 4, malgré quelques observations « éloignées » de la tendance.)

Ces deux graphiques présentent des courbes qui ne suivent visuellement pas une loi normale.

Pour la variable expliquée "duree", en regroupant les observations par années, nous obtenons une tendance baissière : la part d'individus diminue à mesure que ces derniers restent davantage en emploi, dans une même entreprise.

Les données de l'enquête semblent ainsi conforter la croyance selon laquelle les individus présentant de nombreuses années d'expérience dans une même entreprise sont moins communes que ceux l'ayant récemment intégré, ou qui y sont depuis quelques années.

Pour la version logarithmique, en regroupant les observations en trois blocs, nous obtenons une courbe ressemblant très grossièrement à la distribution d'une loi normale.



Les tests de normalité démontrent l'absence de normalité de la variable expliquée "duree", et de sa version logarithmique "ln_duree".

. sktest duree ln_duree, noadjust					
Skewness and kurtosis tests for normality					
Variable	Obs	Pr(skewness)	Pr(kurtosis)	— Joint test — chi2(2)	Prob>chi2
duree	5,495	0.0000	0.0000	3609.08	0.0000
ln_duree	5,495	0.0000	0.0000	709.31	0.0000
. swilk duree ln_duree					
Shapiro-Wilk W test for normal data					
Variable	Obs	W	V	z	Prob>z
duree	5,495	0.94301	167.948	13.483	0.00000
ln_duree	5,495	0.91195	259.473	14.628	0.00000

Ces deux tableaux constituent les tests de normalité.

Nous remarquons que la p-value donnée dans la dernière colonne (Prob>chi2 pour le sktest, et Prob>z pour le swilk) est de 0 pour les deux variables, ce qui signifie que nous pouvons rejeter l'hypothèse de normalité de chacune des variables.

. sum duree, d					. sum ln_duree, d				
duree					ln_duree				
Percentiles	Smallest				Percentiles	Smallest			
1%	1	1			1%	0	0		
5%	4	1			5%	1.386294	0		
10%	6	1	Obs	5,495	10%	1.791759	0	Obs	5,495
25%	12	1	Sum of wgt.	5,495	25%	2.484907	0	Sum of wgt.	5,495
50%	28		Mean	30.20783	50%	3.332205		Mean	3.090417
		Largest	Std. dev.	19.6428			Largest	Std. dev.	.9250038
75%	47	71			75%	3.850147	4.26268		
90%	60	71	Variance	385.8396	90%	4.094345	4.26268	Variance	.855632
95%	64	72	Skewness	.2955335	95%	4.158883	4.276666	Skewness	-1.003189
99%	66	72	Kurtosis	1.834099	99%	4.189655	4.276666	Kurtosis	3.623752

De surcroît, les skewness et kurtosis des deux variables ne valent pas 0 et 3 respectivement, sachant qu'une variable qui suit une loi normale admet un skewness de 0 et un kurtosis de 3.

Ainsi, nous choisissons de poursuivre avec la variable "duree" pour les statistiques bivariées en rapport avec les variables explicatives catégorielles; et de poursuivre avec sa version logarithmique "ln_duree" pour les statistiques bivariées en rapport avec les variables explicatives continues.

Statistiques univariées sur les variables explicatives

- Variable "salcalc" : salaire horaire net en euros (prime incluse)


. tabstat duree salcalc, statistics(mean, min, max, p10, p25, p50, p75, p90) col(stat)							
Variable	Mean	Min	Max	p10	p25	p50	p75
duree	30.20783	1	72	6	12	28	47
salcalc	6.734635	1.6	17.433	2.8	5.133	6.283	8.229
Variable	p90						
duree	60						
salcalc	10.434						

Le tableau de statistiques ci-dessus correspond à celui de la durée en emploi et du salaire horaire net en euros (prime incluse).

Le salaire horaire net moyen de l'échantillon est de 6.68€ net par heure (prime incluse) ; le plus bas s'élevant à 1.6€, contre 17.43€ pour le plus élevé.


La moitié des personnes composant l'échantillon gagnent moins de 6.28€ net par heure (prime incluse), et la tranche des 10% des rémunérations les plus élevées est en moyenne 5.13x supérieure à celle des 10% les plus faibles (12.83€ contre 2.50€ en moyenne pour ces 2 tranches).

. mean salcalc if salcalc>=10.43				
Mean estimation			Number of obs = 555	
	Mean	Std. err.	[95% conf. interval]	
salcalc	12.82854	.078384	12.67458	12.98251
. mean salcalc if salcalc<=2.8				
Mean estimation			Number of obs = 553	
	Mean	Std. err.	[95% conf. interval]	
salcalc	2.497412	.0094534	2.478843	2.515981



Le graphique représentant la répartition de chaque niveau de salaire de l'échantillon témoigne d'une tendance haussière en premier lieu, avant que cette dernière ne s'inverse à partir de 6 à 7 euros.

- **Variable "nivagr_bis" : niveau d'éducation de l'individu**




Le tableau de fréquence ainsi que le graphique ci-dessus accusent une répartition uniforme pour les individus ayant le Baccalauréat, un diplôme équivalent à deux années en études supérieures, et un diplôme équivalent à plus de trois années en études supérieures.

La modalité qui apparaît le plus dans l'échantillon correspond aux personnes ne disposant que d'un CAP ou BEP ; ceux disposant uniquement du brevet des collèges ou aucun diplôme sont regroupés dans la catégorie "Autres" et ne représentent qu'une faible portion de l'échantillon.

En ce sens, environ 60% des observations ne possèdent qu'un CAP/BEP/Bac ; plus d'un tiers de l'échantillon est constitué d'individus ayant un diplôme d'études supérieures ; environ 6% de l'échantillon est représenté par ceux n'ayant que le brevet des collèges ou aucun diplôme.

L'échantillon entre en accord avec ce que nous pouvions penser sur la répartition des niveaux d'éducation, à savoir une majorité de personnes scolarisées jusqu'au lycée, dont une partie jusqu'en études supérieures.

- **Variable "cspe_bis" : catégorie socioprofessionnelle de l'individu**




Le tableau et le graphique ci-dessus représentent la répartition des catégories socio-professionnelles des individus de l'échantillon.

Il y a une majorité d'employés (plus d'un tiers), tandis que la répartition est davantage uniforme entre les quatre autres catégories. De manière générale, les catégories socio-professionnelles élevées (cadres, ingénieurs, techniciens et professions intermédiaires, ...) représentent 1/3 de l'échantillon, contre 2/3 pour les catégories socio-professionnelles faibles (employés, ouvriers qualifiés et non qualifiés).

La répartition des observations au sujet des catégories socioprofessionnelles de l'échantillon semble confirmer la croyance d'une forte représentation des employés et ouvriers dans la population active, et moins de cadres et professions intermédiaires.


- **Variable "taille_bis" : taille de l'entreprise actuelle de l'individu**



Le tableau et le graphique qui lui est associé représentent la répartition de la taille de l'entreprise des individus de l'échantillon.

La répartition des tailles d'entreprises reste uniforme pour les tailles allant de 0 à 500; les entreprises de plus de 500 personnes sont deux fois moins présentes dans l'échantillon par rapport aux autres tailles.


- **Variable "nbent" : nombre d'entreprises dans lesquelles l'individu a travaillé**



Nous pouvons noter que près de 60% de l'échantillon n'a travaillé que dans deux entreprises, au moment de l'enquête; tandis que les 20% restants ont travaillé dans plus de 3 entreprises.

La proportion de personnes n'ayant travaillé que dans une entreprise, ou deux, est plus élevée que celles qui ont travaillé dans 3 ou 4 entreprises et plus : environ 30% pour chacune des deux premières catégories, contre 20% pour les deux dernières.


- **Variable "sexe" : sexe de l'individu**



La répartition entre les personnes de sexe féminin et ceux de sexe masculin est visuellement uniforme, malgré une représentation des personnes de sexe masculin légèrement plus marquée. L'échantillon semble être représentatif de la répartition des sexes dans la population française.

- **Variable "cens" : situation de l'individu**

. ta cens			
Êtes-vous toujours en emploi ?	Freq.	Percent	Cum.
Non	1,132	20.60	20.60
Oui	4,363	79.40	100.00
Total	5,495	100.00	



La majeure partie des personnes interrogées sont toujours en emploi, au moment de l'enquête; il y a ainsi près de 80% de l'échantillon qui disposent d'un emploi au moment de l'enquête, contre 20% qui n'en disposent pas.

Dans l'économie française, un tel taux de chômage, même frictionnel, constitue un taux anormalement élevé : l'échantillon n'est pas représentatif de la répartition de population active française.


4) statistiques descriptives bivariées

Variable continue: salcalc(salaire horaire net)

Le coefficient de corrélation entre "salcalc" et "ln_duree" assorti du test de significativité nous donne:

pwcorr ln_duree salcalc, sig		
	ln_duree	salcalc
ln_duree	1.0000	
salcalc	0.2205	1.0000
	0.0000	

Nous trouvons un coefficient de corrélation égale à 0,2205 et une p-value égale à 0. Donc il y'a une corrélation positive et la p-value étant inférieure à 0,05, nous rejetons H_0 et la corrélation est significative.




Le graphique ci-dessus représente la moyenne de la durée en emploi (en log) selon le salaire horaire net moyen (en log).

Nous observons une relation croissante de la durée en emploi selon le salaire et nous remarquons que cette relation n'est pas totalement linéaire, car à partir d'un certain niveau de salaire, la courbe croît plus rapidement.

Nous pouvons alors suggérer que la relation est davantage convexe que linéaire.

Variables explicatives catégorielles:

1. niveau d'éducation: nivagr_bis




Nous observons une tendance globalement croissante selon le niveau d'éducation:

- L3 et plus, ainsi que L2 DUT BTS sont les catégories avec la durée la plus longue en moyenne ;
- ceux qui ont le bac ou bien un CAP et BEP sont légèrement en dessous ;
- tandis que ceux qui sont dans la catégorie "autres" ont en moyenne une durée en emploi bien plus faible ;

Nous pouvons alors dire qu'il y'a une corrélation positive entre le niveau d'éducation et la durée en emploi.

2) catégorie socio-professionnelle:




Nous observons une tendance globalement croissante selon la csp:

- les cadres et techniciens sont ceux qui ont la durée la plus longue en moyenne ;
- les employés et les ouvriers qualifiés ont en moyenne une durée similaire ;

- tandis que les ouvriers non qualifiés ont en moyenne une durée en emploi bien plus faible ;

Nous pouvons alors dire qu'il y a une corrélation positive entre la csp et la durée en emploi.

3) taille de l'entreprise




Nous observons une tendance positive croissante selon la taille de l'entreprise:

- la durée moyenne en emploi dans les entreprises de 0 à 10, 10 à 50, 50 à 500 est similaire ;
- tandis que la durée en emploi, en moyenne dans les entreprises de plus de 500 personnes, est bien plus élevée.

Nous remarquons alors une corrélation positive entre la taille de l'entreprise et la durée en emploi.


4) Le sexe



Nous observons qu'en moyenne la durée en emploi chez les femmes est plus longue que chez les hommes.

D'après ce graphique il existe bien une corrélation entre le sexe et la durée moyenne de l'emploi.


5) a un emploi ou non



Nous observons qu'en moyenne la durée en emploi pour un individu qui est actuellement en emploi est plus longue.

D'après ce graphique il y'aurait une corrélation positive entre le fait d'être en emploi et la durée moyenne de l'emploi.

6) nombre d'entreprises



Nous observons une tendance négative entre la durée moyenne de l'emploi et le nombre d'entreprises.

Les individus ayant travaillé dans 1 entreprise ont en moyenne une durée en emploi nettement supérieure aux autres.

Les individus ayant travaillé dans 4 entreprises ou plus ont en moyenne une durée en emploi nettement inférieure aux autres.

Nous remarquons alors une corrélation négative entre le nombre d'entreprises et la durée en emploi.

PARTIE 2 : ESTIMATION DU MODÈLE LINÉAIRE MULTIPLE

1) Présentation théorique du modèle estimé

Rappel des hypothèses du modèle de régression linéaire multiple :

- H1 : le modèle est linéaire par rapport à ses coefficients
- H2 : $E[u|(x_1, \dots, x_k)] = 0$
- H3 : absence de colinéarité parfaite entre les variables explicatives $X_1, \dots, X_k$.
- H4 : absence d'autocorrélation des erreurs et homoscedasticité $Cov(u_i, u_j) = 0 \forall i \neq j$ et $Var(u_i) = \sigma_u^2$.

Ici, le modèle vérifie H1 : il est effectivement linéaire par rapport à ses coefficients $\beta_0, \dots, \beta_k$.

Le modèle est aussi formulé de tel sorte à ce que H3 soit vérifiée, auquel cas nous ne pourrions pas appliquer la méthode des MCO ou MCG.

Le modèle ne vérifie toutefois pas H2, car nombreuses sont les variables dans le terme d'erreur qui ne se valent pas entre deux individus.

Par exemple, le modèle ne tient pas compte de l'état de santé de l'individu, qui influence également la durée en emploi.

Or, chaque individu ne dispose pas du même état de santé : une personne cadre avec un salaire très élevé peut se permettre des dépenses en santé, ce qui n'est pas nécessairement le cas pour son homologue ouvrier en situation précaire. Il y a donc un lien entre les variables explicatives du modèle et certaines variables contenues dans la perturbation, et affirmer H2 serait faux, à savoir affirmer : « en moyenne, l'état de santé d'un individu, sa motivation, sa relation avec ses collègues, ... est le même, quel que soit son salaire, sexe, cspe, ... ».

L'hypothèse H2 n'étant pas vérifiée, les estimateurs seront biaisés, et **l'effet des variables explicatives n'est pas causal.**

Le modèle ne vérifie pas aussi H4 : même s'il est réaliste que les perturbations d'un individu n'ont aucun lien avec celles d'un autre, car les données sont issues d'une enquête, il y a une hétéroscédasticité des erreurs.

En effet, les cadres présentent vraisemblablement un état de santé plutôt homogène (ils sont tous plus ou moins en bonne santé), tandis que l'état de santé des ouvriers et employés serait davantage hétérogène (il y a une proportion plus grande de personnes en moyenne ou mauvaise santé par rapport aux cadres).

Ainsi, la variance de l'état de santé n'est pas la même chez les cadres et chez les ouvriers/employés.

(Remarque : les hypothèses H2 et H4 ne sont pas vérifiées, donc les interprétations des relations entre les variables explicatives du modèle avec la durée en emploi sont à nuancer ; elles sont à entendre comme une relation de corrélation et non une relation de causalité. Quant aux tests, même si l'hypothèse de normalité des erreurs n'est pas vérifiée, nous avons quand même décidé de les réaliser, mais nous nous devons de garder à l'esprit que les résultats de ces tests ne sont pas celles avec lesquelles nous pouvons définitivement conclure.)

2 et 3) Résultats des estimations du modèle MCO et commentaires

Premier modèle :

$$\text{durée en emploi}_i = \beta_0 + \beta_1 \text{Salaire}_i + \beta_2 L3_i + \beta_3 L2_i + \beta_4 \text{BEPCAP}_i + \beta_5 \text{AucunDiplôme}_i + u_i$$

. reg duree salcalc ib3.nivagr_bis						
Source	SS	df	MS	Number of obs	=	5,495
Model	167305.912	5	33461.1825	F(5, 5489)	=	94.07
Residual	1952496.75	5,489	355.710831	Prob > F	=	0.0000
				R-squared	=	0.0789
				Adj R-squared	=	0.0781
Total	2119802.66	5,494	385.839582	Root MSE	=	18.86
duree	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
salcalc	1.816191	.1103354	16.46	0.000	1.59989	2.032492
nivagr_bis						
L3 et plus	-2.442544	.9182722	-2.66	0.008	-4.242722	-.642367
L2 DUT BTS	1.929686	.8374102	2.30	0.021	.2880301	3.571342
CAP et BEP	-.5959889	.6813046	-0.87	0.382	-1.931616	.739638
Autres	-5.245294	1.171573	-4.48	0.000	-7.54204	-2.948548
_cons	18.60995	.8548096	21.77	0.000	16.93419	20.28572

La référence est un individu ayant le Bac.

1) Interprétation des coefficients :

La constante donne : 18,61. Nous ne pouvons pas l'interpréter économiquement, car cela signifierait alors qu'en moyenne, un individu qui n'a que le Bac (et un salaire horaire net de 0€) reste en emploi, en moyenne, pendant un peu plus d'un an et 6 mois (18,61 mois).

Le coefficient associé à la variable "salcalc" est de 1.82 : en moyenne, à une augmentation du salaire horaire net de 1€, est associée une augmentation de la durée en emploi de 1.82 mois (soit environ 1 mois et 25 jours si l'on considère un mois-type de 30 jours), **CETERIS PARIBUS** (soit pour un niveau d'éducation donné).

Comparativement à une personne n'ayant que le Bac, et pour un salaire horaire net donné, en moyenne :

- une personne ayant un diplôme de licence ou plus affiche une durée en emploi inférieure de 2 mois et 13 jours (2.44 mois) ;
- Une personne ayant un diplôme de DUT, BTS ou équivalent à deux années de licence, affiche une durée en emploi supérieure d'environ 1 mois et 28 jours (1.93 mois) ;
- Pour les personnes n'ayant que le CAP/BEP ou aucun diplôme, les écarts sont respectivement de 18 jours (0.6 mois) ainsi que 5 mois et 8 jours (5.25 mois), en défaveur de ces derniers.

La relation explicité ici entre la durée en emploi et le niveau d'éducation est intuitive.

L'individu diplômé d'une licence/master/doctorat entre sur le marché du travail plus tard que son homologue diplômé du Bac (ou CAP/BEP).

Tandis que la plus faible durée en emploi chez l'individu sans diplôme, par rapport à son homologue diplômé du Bac, peut être expliquée par une plus grande difficulté à avoir un emploi et rester dans cet emploi, soit une plus grande période de chômage frictionnelle.

2) Significativité du modèle :

La p-value associé au test de Fisher est de 0, donc le modèle est significatif et il existe au moins une variable, parmi les cinq, qui "influence significativement la durée en emploi".

Nous pouvons aussi calculer la statistique de Fisher empirique : $F^* = \frac{\frac{167\ 305.912}{5}}{\frac{1\ 952\ 496.75}{5\ 495-5-1}} = 94.0684 \approx 94,07$.

En la comparant à la statistique de Fisher théorique, au seuil de 5%, soit $F_{5\%}^* = 2.21$, nous obtenons $F^* > F_{5\%}^*$, et nous pouvons rejeter l'hypothèse de non significativité des coefficients.

3) Significativité des coefficients :

Les variables "salcalc", "L3 et plus" et "Autres" sont significatives au seuils de 5% et 1%.

En effet, leur p-value est de 0, donc inférieure à 5% et 1% ; nous pouvons alors rejeter l'hypothèse de non significativité associé à leurs coefficients respectifs.

En ce sens, la durée en emploi est significativement corrélée avec le salaire (CETERIS PARIBUS).

La durée en emploi est aussi significativement différente pour une personne diplômée d'une licence ou plus, ainsi que pour une personne sans diplôme, par rapport à une personne titulaire d'un Bac (CETERIS PARIBUS).

Pour la variable "L2 DUT BTS", elle est significative au seuil de 5% mais de 1%, car sa p-value est inférieure à 5% mais supérieure à 1% (p-value de 2.1%) : la durée en emploi est significativement différente entre une personne titulaire d'un diplôme de deuxième année avec une personne diplômée du Bac, au seuil de 5% mais pas de 1% (CETERIS PARIBUS).

Pour la variable "CAP BEP", elle n'est pas significativement différente de la variable "Bac" au seuil de 5% et 1%, du fait d'une p-value associée de 38.2% ; la durée en emploi d'une personne diplômée d'un CAP/BEP n'est pas significativement différente de celle diplômée du Bac, au seuil de 5% (CETERIS PARIBUS). Nous décidons de ne pas inclure cette variable dans les modèles futurs ; elle sera ainsi considérée en tant que modalité de référence pour la variable d'éducation.

Calculons la statistique de Student pour la variable "salcalc", sous H_0 : $t_{salcalc}^* = \frac{1.8162-0}{0.1103} \approx 16.466 = 16.47$.

Nous comparons avec la statistique théorique de Student au seuil de 5% et 1% : $t_{5\%}^* = 1.96$ et $t_{1\%}^* = 2.576$ (pour un degré de liberté de $5\ 495 - 5 - 1 = 5489$).

Comme $16.47 > 1.96$ et 2.576 , nous décidons de rejeter l'hypothèse H_0 , donc de rejeter la non significativité de la variable "salcalc" : la variable "salcalc" est significativement corrélée à la durée en emploi.

(Remarque : Stata donne une statistique empirique de 16.46, soit une statistique empirique similaire à ce que nous avons obtenu, à une approximation près.)

4) Commentaire sur le R^2 :

R^2 : le R^2 est de 7.89%. Le modèle explique 7.89% des variations de la durée en emploi ; le modèle doit donc introduire d'autres variables explicatives pour pouvoir expliquer davantage les variations de la durée en emploi.

$$R^2 = \frac{SCE}{SCT} = \frac{167\,305.912}{2\,119\,802.66} \approx 0.07893 = 7.89\%.$$

Deuxième modèle :

$$\text{durée en emploi}_i = \beta_0 + \beta_1 \text{Salaire}_i + \beta_2 L3_i + \beta_3 L2_i + \beta_4 \text{AucunDiplôme}_i + \beta_5 \text{Sexe}_i + \beta_6 \text{Cadre}_i + \beta_7 \text{Technicien}_i + \beta_8 OQ_i + \beta_9 ONQ_i + u_i$$

. reg duree salcalc ib1.sexe_bis ib3.nivagr_bis_corrige ib3.cspe_bis						
Source	SS	df	MS	Number of obs = 5,495		
Model	208441.44	9	23160.1599	F(9, 5485)	=	66.46
Residual	1911361.22	5,485	348.470597	Prob > F	=	0.0000
				R-squared	=	0.0983
				Adj R-squared	=	0.0969
Total	2119802.66	5,494	385.839582	Root MSE	=	18.667

duree	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
salcalc	2.314858	.1219333	18.98	0.000	2.075821	2.553896
sexe_bis être Femme	5.408344	.6049717	8.94	0.000	4.222359	6.594328
nivagr_bis_corrige L3 et plus	-2.288764	1.039155	-2.20	0.028	-4.325919	-.2516087
L2 DUT BTS	1.928625	.794256	2.43	0.015	.371568	3.485681
Autres	-4.204175	1.083912	-3.88	0.000	-6.329073	-2.079277
cspe_bis Cadre	-3.444481	1.180887	-2.92	0.004	-5.759487	-1.129475
Technicien	-1.75445	.8173517	-2.15	0.032	-3.356784	-.1521168
Ouvrier qualifié	1.190952	.8360839	1.42	0.154	-.4481039	2.830008
Ouvrier non qualifié	-1.553955	.8448302	-1.84	0.066	-3.210157	.1022475
_cons	13.27468	.9706413	13.68	0.000	11.37184	15.17752

Le deuxième modèle introduit les variables "sociales", en complément au premier modèle, à savoir le sexe et la catégorie socio-professionnelle de l'individu.

La référence est un homme, diplômé du Bac (ou du CAP/BEP), employé.

1) Interprétation des coefficients

Suite à l'ajout des variables "sexe" et "cspe", nous remarquons que la constante a diminué à 13.27, par rapport à 18.61 dans le premier modèle.

Pour la même raison que celle citée pour le premier modèle, l'interprétation de la constante est absurde.

Au sujet de la variable d'éducation, nous remarquons, par rapport à un individu diplômé du Bac :

- le coefficient associé à un individu sans diplôme s'est atténué d'un mois, passant d'une différence de 5 mois et 8 jours (5.25 mois) à 4 mois et 6 jours (4.2 mois).
- Le coefficient associé à un individu diplômé d'une licence/master/doctorat s'est aussi légèrement atténué. Elle se valorise désormais à un écart négatif de 2 mois et 9 jours (2.3 mois) contre 2 mois et 13 jours (2.44 mois) dans le premier modèle.

Cela signifie, par exemple : dans la catégorie des **femmes cadres, rémunérés 10€/h**, à celle diplômée d'une licence/master/doctorat est associée une durée en emploi d'en moyenne de 2 mois et 9 jours de moins que celle seulement diplômée du Bac (ou du CAP/BEP) ; contre une différence d'en moyenne de 2 mois et 13 jours dans le premier modèle.

En revanche, le coefficient associé au salaire a augmenté jusqu'à 2.31 mois (contre 1.82 mois auparavant) : **CETERIS PARIBUS**, à une augmentation d'un euro du salaire horaire net est associé une

plus forte augmentation moyenne de la durée en emploi, par rapport au premier modèle (2 mois et 9 jours en moyenne, contre 1 mois et 24 jours en moyenne).

En d'autres termes, si nous prenons un exemple : dans la catégorie des **hommes cadres et diplômés d'un Bac/CAP/BEP**, en moyenne, pour une augmentation du salaire horaire net de 1€ est associée une augmentation de la durée en emploi de 2 mois et 9 jours dans le deuxième modèle, contre une augmentation de la durée en emploi de 1 mois et 24 jours dans le premier modèle.

Le modèle nous montre que l'introduction des variables "sociales" contribue à diminuer, même légèrement, les écart de durée en emploi entre les différents niveaux d'éducation ; mais ces écarts s'en retrouvent augmentés, concernant le salaire horaire net.

En moyenne, à **niveau de diplôme, niveau de salaire, et CSPE donnés**, au fait d'être de sexe féminin plutôt que de sexe masculin, est associée une augmentation de la durée en emploi de 5 mois et 12 jours (5.41 mois).

Par exemple, dans la catégorie **des individus sans diplôme, gagnant 10€ net/heure et qui occupent un poste d'ouvrier qualifié/ouvrière qualifiée**, au fait d'être une femme est associée une durée en emploi supérieure de 5 mois et 12 jours par rapport au fait d'être un homme.

Comparativement à un individu employé, et pour un individu de **même sexe, même niveau d'éducation et de salaire**, en moyenne :

- À un(e) cadre est associé une durée en emploi inférieure de 3 mois et 13 jours (3.44 mois) ;
- À un(e) technicien(ne) est associé une durée en emploi inférieure d'un mois et 23 jours (1.754 mois) ;
- À un ouvrier qualifié/ouvrière qualifiée est associé une durée en emploi supérieure d'un mois et 6 jours (1.191 mois), mais cet écart n'est pas significatif au seuil de 5% (la p-value vaut 14.3% > 5%) ; il n'y a pas réalistiquement de différence de durée en emploi entre ces deux catégories socio-professionnelles ;
- À un ouvrier non qualifié/ouvrière non qualifiée est associée une durée en emploi inférieure d'un mois et 16 jours (1.554 mois), mais cet écart n'est pas significatif au seuil de 5% (la p-value vaut 7.8% > 5%) ; il n'y a pas réalistiquement de différence de durée en emploi entre ces deux catégories socio-professionnelles.

Cela signifie, par exemple : en moyenne, à une technicienne **sans diplôme et rémunérée 8€ net/h**, est associée une durée en emploi inférieure de 3 mois et 13 jours par rapport à une employée **aussi sans diplôme et rémunérée 8€ net/h**.

2) Significativité du modèle :

La p-value associé au test de Fisher est de 0, donc le modèle est "significatif et il existe au moins une variable, parmi les neuf, qui influence significativement la durée en emploi".

Nous pouvons aussi calculer la statistique de Fisher empirique : $F^* = \frac{208\,441.44}{\frac{1\,911\,361.22}{5\,495-9-1}} = 66.4623 \approx 66.46$.

En la comparant à la statistique de Fisher théorique, au seuil de 5%, soit $F_{5\%}^* = 1.88$, nous obtenons $F^* > F_{5\%}^*$, et nous pouvons rejeter l'hypothèse de non significativité des coefficients.

3) Significativité des coefficients :

Parmi les neuf variables du modèle (constante exclue), deux sont non significatives. Ce sont les variables "ouvrier qualifié" et "ouvrier non qualifié".

En effet, leurs p-value s'élèvent respectivement à 15,4% et 6,6% : la durée en emploi des individus qui occupent un poste d'ouvrier qualifié ou non qualifié n'est pas significativement différente de celle d'un employé, au seuil de 5%.

Par la suite, nous déciderons de ne pas inclure ces deux variables dans le modèle; elles seront mises en référence.

4) Commentaire sur le R^2 :

R^2 : le R^2 est de 9.83%.

$$R^2 = \frac{SCE}{SCT} = \frac{208\,441.44}{2\,119\,802.66} \approx 0.09833 = 9.83\%.$$

$$\bar{R}^2 = 1 - \frac{N-1}{N-k-1} (1 - R^2) = 1 - \frac{5\,495-1}{5\,495-9-1} (1 - 0.09833) \approx 0.09685 = 9.69\%.$$

Le modèle explique 9.83% des variations de la durée en emploi. En comparant avec le premier modèle, nous regardons les $\bar{R}^2$, qui sont respectivement de 7.81% et 9.69% ; le deuxième modèle présente un $\bar{R}^2$ plus élevé que le premier, et il est donc meilleur.

Troisième modèle :

$$\begin{aligned} \text{durée en emploi}_i = & \beta_0 + \beta_1 \text{Salaire}_i + \beta_2 L3_i + \beta_3 L2_i + \beta_4 \text{AucunDiplôme}_i + \beta_5 \text{Sexe}_i \\ & \beta_6 \text{Cadre}_i + \beta_7 \text{Technicien}_i + \beta_8 \text{chômage}_i + \beta_9 \text{taille1}_i + \beta_{10} \text{taille2}_i + \beta_{11} \text{taille3}_i \\ & + \beta_{12} \text{exp1}_i + \beta_{13} \text{exp2}_i + \beta_{14} \text{exp3}_i + u_i \end{aligned}$$

. reg duree salcalc ib0.sexe_bis ib3.nivagr_bis_corrige ib3.cspe_bis_corrige ib1.cens ib2.taille_bis ib1.nbent_bloc							
Source	SS	df	MS	Number of obs = 5,495			
Model	911465.363	14	65104.6688	F(14, 5480) = 295.26			
Residual	1208337.3	5,480	220.499507	Prob > F = 0.0000			
				R-squared = 0.4300			
				Adj R-squared = 0.4285			
Total	2119802.66	5,494	385.839582	Root MSE = 14.849			
duree	Coefficient	Std. err.	t	P> t	[95% conf. interval]		
salcalc	1.512244	.1060283	14.26	0.000	1.304386	1.720101	
sexe_bis être Femme	4.367975	.4274905	10.22	0.000	3.529924	5.206026	
nivagr_bis_corrige L3 et plus	-3.000901	.8259425	-3.63	0.000	-4.620077	-1.381726	
L2 DUT BTS	2.669235	.6245958	4.27	0.000	1.444779	3.893691	
Autres	-6.253704	.863325	-7.24	0.000	-7.946163	-4.561244	
cspe_bis_corrige Cadre	-2.623684	.9111487	-2.88	0.004	-4.409897	-.8374707	
Technicien	-1.121189	.6033921	-1.86	0.063	-2.304077	.0616989	
cens Non	-9.536772	.53492	-17.83	0.000	-10.58543	-8.488117	
taille_bis 0 à 10	.1422508	.549948	0.26	0.796	-.9358656	1.220367	
50 à 500	.0875365	.5334135	0.16	0.870	-.9581657	1.133239	
plus de 500	.1961168	.6471855	0.30	0.762	-1.072624	1.464857	
nbent_bloc 2 entreprises	-15.67819	.5198312	-30.16	0.000	-16.69727	-14.65912	
3 entreprises	-22.85668	.5826531	-39.23	0.000	-23.99891	-21.71445	
4 entreprises ou plus	-28.66542	.5896633	-48.61	0.000	-29.8214	-27.50945	
_cons	36.07509	.8775379	41.11	0.000	34.35476	37.79541	

Le troisième modèle introduit les variables "extérieures", à savoir celles relatives à l'entreprise. La référence est : un homme, diplômé du Bac (ou CAP/BEP), employé (ou ouvrier qualifié/non qualifié), toujours en emploi, dans une entreprise de 10 à 50 personnes, et qui n'a travaillé que dans une seule entreprise depuis son entrée dans la sphère professionnelle.

1) Interprétation des coefficients

Suite à l'ajout des variables "extérieures", la constante a bondi, passant de 13.27 mois dans le modèle précédent à 36.08 mois dans ce modèle.

Au sujet de la variable d'éducation :

- Les coefficients relatifs aux individus diplômés d'une licence/master/doctorat et ceux sans diplôme sont devenus davantage négatifs, passant respectivement à - 3 mois et - 6.25 mois (contre - 2.3 mois et -4.2 mois dans le modèle précédent).
- Le coefficient associé à un individu diplômé d'un diplôme de L2/BTS/DUT a augmenté de près de 22 jours (2.67 mois désormais contre 1.93 mois précédemment).

Désormais, au fait d'être une femme plutôt qu'un homme, est associé une augmentation de la durée en emploi plus faible que dans le modèle précédent (**CETERIS PARIBUS**) : l'écart se décline ici à 4 mois et 11 jours contre 5 mois et 12 jours anciennement (4.37 mois contre 5.41 mois), **CETERIS PARIBUS**.

Au sujet de la CSP de l'individu, la durée en emploi des individus cadres et techniciens ont respectivement augmenté de 24 jours et 19 jours par rapport à leurs valeurs dans le modèle précédent (- 2.62 mois contre - 3.44 mois, et - 1.12 mois contre - 1.75 mois).

Le modèle nous montre que l'introduction des variables "extérieures" contribue à lisser les écarts de durée en emploi entre les différentes catégories socio-professionnelles et les sexes, mais à agrandir ces écarts entre les niveaux d'éducation.

Pour éviter d'avoir à interpréter chaque coefficient deux fois de suite, nous décidons d'abord de retirer du modèle les variables non significatives, avant d'interpréter les coefficients.

En ce sens, la taille de l'entreprise n'est pas une variable significative, et la durée en emploi pour un technicien n'est pas significativement différente de celle d'un employé/ouvrier qualifié ou non qualifié, au seuil de 5% (**CETERIS PARIBUS**). Nous pouvons donc les soustraire du modèle.

Le modèle final est le suivant :

$$\begin{aligned} \text{durée en emploi}_i = & \beta_0 + \beta_1 \text{Salaire}_i + \beta_2 \text{L3}_i + \beta_3 \text{L2}_i + \beta_4 \text{AucunDiplôme}_i + \beta_5 \text{Sexe}_i \\ & + \beta_6 \text{Cadre}_i + \beta_7 \text{Technicien}_i + \beta_8 \text{chômage}_i + \beta_9 \text{exp1}_i + \beta_{10} \text{exp2}_i + \beta_{11} \text{exp3}_i + u_i \end{aligned}$$

```
. reg duree salcalc ib0.sexe_bis ib3.nivagr_bis_corrige ib2.cspe_bis_corrige_2 ib1.cens ib1.nbent_bloc
```

Source	SS	df	MS	Number of obs	=	5,495
Model	910671.216	10	91067.1216	F(10, 5484)	=	413.03
Residual	1209131.45	5,484	220.483488	Prob > F	=	0.0000
				R-squared	=	0.4296
				Adj R-squared	=	0.4286
Total	2119802.66	5,494	385.839582	Root MSE	=	14.849

	duree	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
	salcalc	1.485265	.1008446	14.73	0.000	1.28757	1.682961
	sexe_bis être Femme	4.385902	.4272604	10.27	0.000	3.548303	5.223502
	nivagr_bis_corrige L3 et plus	-3.465669	.7864929	-4.41	0.000	-5.007507	-1.923831
	L2 DUT BTS	2.275483	.5884098	3.87	0.000	1.121967	3.429
	Autres	-6.193203	.8622119	-7.18	0.000	-7.883481	-4.502926
	cspe_bis_corrige_2 Cadre	-1.930343	.8249202	-2.34	0.019	-3.547514	-.3131723
	cens Non	-9.569277	.5341917	-17.91	0.000	-10.61651	-8.52205
	nbent_bloc 2 entreprises	-15.6735	.5193228	-30.18	0.000	-16.69158	-14.65542
	3 entreprises	-22.85461	.5812538	-39.32	0.000	-23.9941	-21.71512
	4 entreprises ou plus	-28.68759	.5876085	-48.82	0.000	-29.83954	-27.53565
	_cons	36.19239	.8179771	44.25	0.000	34.58883	37.79595

Dans ce modèle final, la référence est : un homme, diplômé du Bac (ou CAP/BEP), employé (ou technicien, ouvrier qualifié/non qualifié), toujours en poste, ayant travaillé dans une seule entreprise au cours de sa vie.

1) Interprétation des coefficients

La constante s'élève à 36.19 mois. Pour les mêmes raisons que celles explicitées dans le premier modèle, elle n'est pas interprétable.

CETERIS PARIBUS, en moyenne, à une augmentation d'un euro du salaire horaire net, est associé une augmentation de la durée en emploi de 1 mois et 15 jours (1.49 mois).

La relation est intuitive, même si les études économiques expliquent souvent la relation inverse.

CETERIS PARIBUS, en moyenne, au fait d'être une femme plutôt qu'un homme, est associé une durée en emploi supérieure de 4 mois et 12 jours (4.39 mois).

Si nous avançons l'argument de la "diversité de genre en entreprise", la relation devient intuitive, et elle devient d'autant plus intuitive dans les professions où les femmes sont sous-représentées.

Comparativement à un individu diplômé du Bac (ou CAP/BEP), **CETERIS PARIBUS**, en moyenne :

- Un individu diplômé d'une licence/master/doctorat présente une durée en emploi inférieure de 3 mois et 14 jours (3.47 mois) ;
- Un individu diplômé d'un diplôme équivalent à deux années de licence présente une durée en emploi supérieure de 2 mois et 8 jours (2.28 mois) ;
- Un individu sans diplôme présente une durée en emploi inférieure de 6 mois et 6 jours (6.19 mois).

La relation explicitée ici entre la durée en emploi et le niveau d'éducation est intuitive.

L'individu diplômé d'une licence/master/doctorat entre sur le marché du travail plus tard que son homologue diplômé du Bac (ou CAP/BEP).

Tandis que la plus faible durée en emploi chez l'individu sans diplôme, par rapport à son homologue diplômé du Bac, peut être expliquée par une plus grande difficulté à avoir un emploi et rester dans cet emploi, soit une plus grande période de chômage frictionnelle.

Comparativement à un individu occupant le poste d'employé (ou de technicien ou d'ouvrier qualifié/non qualifié), en moyenne, un individu occupant le poste de cadre présente une durée en emploi inférieure d'un mois et 28 jours (1.93 mois), **CETERIS PARIBUS**.

L'écart de durée en emploi est intuitive, car les postes de cadres sont relativement rares par rapport aux professions nécessitant des niveaux d'éducation plus faibles ; cela prend donc plus de temps d'accéder à un poste de cadre qu'un poste requérant moins de compétences.

Jusqu'ici, les différences de durées en emploi semblent "petites", dans la mesure où elles ne dépassent quasiment pas 6 mois.

Toutefois, ces écarts sont bien plus grands lorsque nous portons notre attention sur les variables "extérieures", en particulier sur le nombre d'entreprises où l'individu est passé au cours de sa vie.

Comparativement à un individu au chômage, en moyenne, au fait d'être toujours en poste, est associé une durée en emploi supérieure de 9 mois et 17 jours (9.569 mois), **CETERIS PARIBUS**.

La différence est intuitive, car (re)trouver un emploi ne se fait généralement pas en quelques jours ; toutefois, l'écart est plus important que ce que nous pouvions penser (sachant que nous comparons deux individus similaires, qui ne se différencient que par leur situation professionnelle).

Le tableau suivant nous montre que le taux de chômage atteint 20.60% de l'échantillon, ce qui traduit très probablement un marché de l'emploi fragile (au moment de l'enquête).

. ta cens			
Êtes-vous toujours en emploi ?	Freq.	Percent	Cum.
Non	1,132	20.60	20.60
Oui	4,363	79.40	100.00
Total	5,495	100.00	

Comparativement à un individu n'ayant travaillé que dans une seule entreprise au cours de sa vie,

CETERIS PARIBUS, en moyenne :

- À un individu ayant travaillé dans deux entreprises, est associé une durée en emploi inférieure d'un an, trois mois et 20 jours (15.67 mois) ;
- À un individu ayant travaillé dans trois entreprises, est associé une durée en emploi inférieure d'un an, dix mois et 26 jours (22.86 mois) ;
- À un individu ayant travaillé dans 4 entreprises ou plus, est associé une durée en emploi inférieure de deux ans, 4 mois et 21 jours (28.69 mois).

La relation est intuitive, car entre chaque poste par lequel un individu est passé, ce dernier a dû passer par le chômage frictionnel. Plus l'individu possède d'expériences dans différentes entreprises, plus longtemps il sera resté au chômage frictionnel par rapport à un individu ayant connu moins d'expériences différentes.

2) Significativité du modèle

La p-value associé au test de Fisher est de 0, donc le modèle est "significatif et il existe au moins une variable, parmi les neuf, qui influence significativement la durée en emploi".

Nous pouvons aussi calculer la statistique de Fisher empirique : $F^* = \frac{\frac{910\ 671.216}{10}}{\frac{1\ 209\ 131.45}{5\ 495 - 10 - 1}} \approx 413.033 = 413.033$.

En la comparant à la statistique de Fisher théorique, au seuil de 5%, soit $F_{5\%}^* = 1.83$, nous obtenons $F^* > F_{5\%}^*$, et nous pouvons rejeter l'hypothèse de non significativité des coefficients.

3) Significativité des coefficients

L'ensemble des coefficients est significatif au seuil de 5% ; les p-values sont toutes égales à 0%.

Par exemple, pour la variable "cens" (situation professionnelle) : sous H_0 , $t_{cens}^* = \frac{-9.569-0}{0.5342} \approx 17.9128 = 17.91$.

Nous comparons avec la statistique théorique de Student au seuil de 5% et 1% : $t_{5\%}^* = 1.96$ et $t_{1\%}^* = 2.576$ (pour un degré de liberté de $5\ 495 - 10 - 1 = 5484$).

Comme $17.91 > 1.96$ et 2.576 , nous décidons de rejeter l'hypothèse H_0 : la variable "cens" est significativement corrélée à la durée en emploi.

4) Commentaire sur le R^2

R^2 : le R^2 est de 42.96%.

$$R^2 = \frac{SCE}{SCT} = \frac{910\,671.216}{2\,119\,802.66} \approx 0.4296 = 42.96\%.$$

$$\bar{R}^2 = 1 - \frac{N-1}{N-k-1} (1 - R^2) = 1 - \frac{5\,495 - 1}{5\,495 - 10 - 1} (1 - 0.4296) \approx 0.42855 = 42.86\%.$$


Le modèle explique 42.96% des variations de la durée en emploi. En comparant avec le deuxième modèle, nous regardons les $\bar{R}^2$, qui sont respectivement de 9.69% et 42.86% ; le modèle final présente un $\bar{R}^2$ plus élevé que le deuxième modèle (et le premier modèle), et il est donc meilleur.

4) Tests de détection de l'hétéroscédasticité

4.1 – analyse graphique de la forme des résidus

Dans cette partie, nous tentons d'analyser la forme graphique des résidus (au carré) en fonction de :


- 1) La durée en emploi – variable "duree" ;
- 2) Le salaire horaire net (prime incluse) – variable "salcalc" ;
- 3) Le nombre d'entreprise – variable "nbent" (et non "nbent_bloc", car ici, regrouper fait perdre de l'information).



Nous remarquons que la forme des résidus (au carré) présente un creux aux alentours de 35 mois et présente une forme en "V". De manière générale, les résidus (au carré) semblent augmenter à mesure que la durée en emploi (estimée) augmente.

Il y a donc hétéroscédasticité en forme de "V".


Représentation des résidus (au carré) selon le salaire horaire net (prime incluse)



Ici aussi, en prenant la variable de salaire, nous remarquons qu'il y a de l'hétéroscédasticité : les résidus (au carré) augmentent dans un premier temps jusqu'à un niveau de salaire horaire net de 10€, puis les valeurs diminuent drastiquement après 10€.

La forme de l'hétéroscédasticité est d'abord croissante, avant d'être décroissante.

Représentation des résidus (au carré) selon le nombre des entreprises dans lesquelles l'individu a travaillé.



Ici aussi, concernant les entreprises pour lesquelles l'individu a travaillé, nous remarquons : plus l'individu a travaillé dans différentes entreprises, plus faibles sont les résidus (au carré).

La forme de l'hétéroscédasticité est ici décroissante (mais non linéaire, du fait des changements drastiques après 5 entreprises).

4.2 – Tests d'hétéroscédasticité

Test de Breusch – Pagan

En créant une régression auxiliaire avec comme variable expliquée les résidus au carré, nous obtenons le tableau suivant avec Stata :

. reg res2 salcalc ib1.sexe_bis ib3.nivagr_bis_corrige ib2.cspe_bis_corrige_2 ib1.cens ib1.nbent_bloc						
Source	SS	df	MS	Number of obs	= 5,495	
Model	14662900.1	10	1466290.01	F(10, 5484)	= 19.29	
Residual	416795286	5,484	76002.058	Prob > F	= 0.0000	
				R-squared	= 0.0340	
				Adj R-squared	= 0.0322	
Total	431458186	5,494	78532.6148	Root MSE	= 275.68	
res2	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
salcalc	-7.556127	1.872308	-4.04	0.000	-11.22659	-3.885661
sexe_bis être Femme	27.46638	7.932631	3.46	0.001	11.91527	43.01748
nivagr_bis_corrige L3 et plus	-16.01641	14.60224	-1.10	0.273	-44.64259	12.60977
L2 DUT BTS	-17.74733	10.92457	-1.62	0.104	-39.16383	3.669165
Autres	26.47752	16.00806	1.65	0.098	-4.904622	57.85966
cspe_bis_corrige_2 Cadre	23.49102	15.31569	1.53	0.125	-6.533806	53.51585
cens Non	-74.97349	9.917947	-7.56	0.000	-94.4166	-55.53038
nbent_bloc 2 entreprises	8.293511	9.641886	0.86	0.390	-10.60841	27.19543
3 entreprises	-44.04514	10.79171	-4.08	0.000	-65.20118	-22.8891
4 entreprises ou plus	-88.73516	10.9097	-8.13	0.000	-110.1225	-67.34782
_cons	298.7655	15.18678	19.67	0.000	268.9933	328.5376

Le modèle auxiliaire est : $\hat{u}_i^2 = \delta_0 + \delta_1 \text{salcalc}_i + \dots + \delta_{10} \text{"quatre entreprises ou plus"}_i + v_i$

- Test de Breusch – Pagan à travers la statistique de Fisher :

Le test est :

$H_0 := \delta_i = 0 \forall i = 1, \dots, 10$ (les coefficients associés aux variables explicatives sont toutes égales à 0 ; la variance des erreurs est constante).

$H_1 := \exists i \in \{1, \dots, 10\}, \delta_i \neq 0$ (il y a au moins une variable, parmi les dix, dont le coefficient est non nul ; la variance des erreurs n'est pas constante).

Grâce à la sortie STATA, nous obtenons la statistique de Fisher suivante: $F^* = 19,29$ avec $F^* \sim F(10, 5\,484)$.

En effet, nous avons $F^* = \frac{\left(\frac{0.034}{10}\right)}{\left(\frac{1-0.034}{5\,495-10-1}\right)} \approx 19,301 = 19,3$ (qui est légèrement supérieure à la sortie STATA, lorsque nous la calculons à la main).

Or, au seuil de 5%, nous avons $F_{5\%}^* = 1,83$; et à 1%, nous avons $F_{1\%}^* = 2,32$.

Nous remarquons que $19,29 > 2,32 > 1,83$: l'hypothèse H_0 est rejetée aux seuils de 5% et 1%.

La régression auxiliaire est globalement significative, ce qui met en évidence l'existence d'une variable à l'origine de l'hétéroscédasticité (très marquée).

- Test de Breusch – Pagan à travers la statistique LM :

$LM = N \times R^2 = 5\,495 \times 0,0340 = 186,83$ et où $LM \sim \chi^2(10)$.

Nous avons $\chi^2_{5\%} = 18,31$ et $\chi^2_{1\%} = 23,21$.

Comme $186,83 > 18,31$ et $23,21$, nous pouvons rejeter l'hypothèse H_0 aux seuils de 5% et 1% ; et la conclusion reste identique à celle énoncée précédemment.

Test de Goldfed et Quandt

Pour effectuer ce test, la variables explicative sélectionnée est le salaire horaire net (prime incluse). Nous allons donc vérifier si la variance des perturbations est une fonction de la variable "salcalc", comme ce que peut affirmer l'analyse graphique.

Le test est :

$H_0 := Var(u_i) = \sigma^2 \forall i = 1, \dots, 5495$. Cela signifie que les variances des perturbations sont les mêmes, et ce, pour chaque individu (homoscédasticité) ; ou que l'hétéroscédasticité ne se présente pas sous cette forme.

$H_1 := Var(u_i) = \sigma^2 z_i \forall i = 1, \dots, 5495$. Cela signifie qu'il existe une fonction z_i pour chaque individu, telle que la variance des erreurs dépend du niveau de salaire horaire net (hétéroscédasticité).

La taille globale de l'échantillon est $N = 5495$.

Pour appliquer le test de Goldfeld-Quandt, nous devons d'abord trier la base de données selon les valeurs de "salcalc".

Puis, il nous faudra 2 échantillons : nous retirons tout d'abord C observations centrales de l'échantillon, avec $C = N/4 = 1373,75$.

A partir de l'observation du milieu (2 747,45), nous retirons $C/2 = 686,875$ des deux côtés, pour obtenir :

- $n_1 \leq 2\,060$ (premier échantillon) ;
- $n_2 \geq 3\,436$ (deuxième échantillon).

Avec STATA, nous obtenons :

```

. sort salcalc
. reg duree salcalc ib1.sexe_bis ib3.nivagr_bis_corrige ib2.cspe_bis_corrige_2 ib1.cens ib1.nbent_bloc if _n<=2060

```

Source	SS	df	MS	Number of obs	=	2,060
Model	217963.384	10	21796.3384	F(10, 2049)	=	94.57
Residual	472255.196	2,049	230.480818	Prob > F	=	0.0000
				R-squared	=	0.3158
				Adj R-squared	=	0.3124
Total	690218.58	2,059	335.220291	Root MSE	=	15.182

	duree	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
	salcalc	2.529238	.3099741	8.16	0.000	1.921341	3.137135
	sexe_bis être Femme	4.663326	.718238	6.49	0.000	3.254774	6.071879
	nivagr_bis_corrige L3 et plus	-.7750076	1.798826	-0.43	0.667	-4.302725	2.75271
	L2 DUT BTS	2.09363	1.396795	1.50	0.134	-.6456569	4.832916
	Autres	-5.328009	1.084222	-4.91	0.000	-7.454302	-3.201717
	cspe_bis_corrige_2 Cadre	1.465965	2.79574	0.52	0.600	-4.016824	6.948754
	cens Non	-7.805904	.7201811	-10.84	0.000	-9.218267	-6.393541
	nbent_bloc 2 entreprises	-12.71623	.8793777	-14.46	0.000	-14.44079	-10.99166
	3 entreprises	-18.55359	.9875169	-18.79	0.000	-20.49023	-16.61695
	4 entreprises ou plus	-23.1888	.9670481	-23.98	0.000	-25.0853	-21.2923
	_cons	26.95449	1.6939	15.91	0.000	23.63254	30.27643

```

. scalar df1 = e(df_r)
.
. scalar scr1 = e(rss)

```

En effectuant une régression sur le premier échantillon, nous obtenons les variables "df1" et "SCR1" qui correspondent respectivement aux degrés de liberté et la somme des carrés des résidus de cette régression ; la variable "df1" vaut 2 049, et la variable "SCR1" vaut 472 255,196.

```

. reg duree salcalc ib1.sexe_bis ib3.nivagr_bis_corrige ib2.cspe_bis_corrige_2 ib1.cens ib1.nbent_bloc if _n>=3436

```

Source	SS	df	MS	Number of obs	=	2,060
Model	364520.679	10	36452.0679	F(10, 2049)	=	186.70
Residual	400051.909	2,049	195.242513	Prob > F	=	0.0000
				R-squared	=	0.4768
				Adj R-squared	=	0.4742
Total	764572.588	2,059	371.332	Root MSE	=	13.973

	duree	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
	salcalc	.5087142	.1628478	3.12	0.002	.1893497	.8280787
	sexe_bis être Femme	4.254079	.6747539	6.30	0.000	2.930804	5.577354
	nivagr_bis_corrige L3 et plus	-3.085139	1.005102	-3.07	0.002	-5.056266	-1.114011
	L2 DUT BTS	2.012699	.8219755	2.45	0.014	.4007047	3.624694
	Autres	-.6397514	2.657624	-0.24	0.810	-5.851678	4.572175
	cspe_bis_corrige_2 Cadre	-1.162729	.9017801	-1.29	0.197	-2.93123	.6057725
	cens Non	-10.05934	1.287123	-7.82	0.000	-12.58354	-7.535134
	nbent_bloc 2 entreprises	-17.89184	.7823689	-22.87	0.000	-19.42616	-16.35752
	3 entreprises	-26.9008	.8883734	-30.28	0.000	-28.64301	-25.15859
	4 entreprises ou plus	-34.14062	.9375409	-36.42	0.000	-35.97925	-32.30198
	_cons	47.94112	1.616097	29.66	0.000	44.77176	51.11048

```

. scalar df2 = e(df_r)
.
. scalar scr2 = e(rss)

```

La régression sur le deuxième sous-échantillon nous donne les variables "df2" et "SCR2", qui correspondent respectivement aux degrés de liberté et la somme des carrés des résidus de cette deuxième régression ; la variable "df2" vaut 2 049, et la variable "SCR2" vaut 400 051,909.

Nous avons :

- "df1" = 2 049 et "SCR1" = 472 255,196 ;
- "df2" = 2 049 et "SCR2" = 400 051,909.

```
. scalar GQ=(scr1/df1)/(scr2/df2)

. scalar pv = Ftail(df1, df2, GQ)

. dis GQ
1.1804848

. dis pv
.00008745
```

Nous calculons la statistique de test ainsi que la p-value, et il faut s'assurer de mettre la SCR la plus élevée au numérateur.

$$GQ = \frac{\left(\frac{472\,255,196}{2\,049}\right)}{\left(\frac{400\,051,909}{2\,049}\right)} \approx 1,1804847955369 = 1,1804848.$$

Sous H_0 , $GQ \sim F(2\,049, 2\,049)$; et la statistique de Fisher théorique est $F_{5\%}^* = 1$.

Nous avons $GQ > F_{5\%}^*$ ($1,1804848 > 1$), donc nous pouvons rejeter l'hypothèse H_0 au seuil de 5%.

Remarquons aussi que la p-value s'élève à $0,00008745 < 0,05$; nous pouvons alors rejeter l'hypothèse H_0 au seuil de 5%, ce qui signifie qu'il existe une différence significative de variance entre les groupes d'individus classés selon le salaire, au seuil de 5%.

Test de Gleisjer

Ce test permet de tester l'existence d'hétéroscédasticité et de trouver sa forme.

Nous commençons par calculer la valeur absolue des résidus estimés.

Puis, nous réaliserons plusieurs régressions pour essayer de trouver la meilleure forme supposée de l'hétéroscédasticité ; ce sera celle qui aura la plus grande valeur pour la statistique de Student.

Nous proposons quatre modèles :

Nous pensons que la variable "salcalc" est celle qui est la cause de l'hétéroscédasticité.

- 1) $|\hat{u}_i| = \alpha + \beta \text{salcalc}_i + \eta_i$ (la variance des erreurs dépend linéairement du salaire horaire net) ;
- 2) $|\hat{u}_i| = \alpha + \beta \sqrt{\text{salcalc}_i} + \eta_i$ (la variance croît avec le salaire horaire net, mais la relation est concave) ;
- 3) $|\hat{u}_i| = \alpha + \beta \frac{1}{\text{salcalc}_i} + \eta_i$ (la variance croît avec le salaire horaire net, mais l'augmentation est de plus en plus faible) ;
- 4) $|\hat{u}_i| = \alpha + \beta \frac{1}{\sqrt{\text{salcalc}_i}} + \eta_i$ (la variance croît lentement avec le salaire horaire net, mais l'augmentation est de plus en plus faible).

Notons que dans chaque modèle, la statistique de Student suit une loi de Student à 5 493 degrés de liberté.

Les t de Student théoriques associés, aux seuils de 5% et 1% sont respectivement de 1,96 et 2,58.

Premier modèle : $|\hat{u}_i| = \alpha + \beta \text{salcalc}_i + \eta_i$

. reg abs_res salcalc						
Source	SS	df	MS	Number of obs	=	5,495
Model	801.513826	1	801.513826	F(1, 5493)	=	11.11
Residual	396300.239	5,493	72.1464116	Prob > F	=	0.0009
				R-squared	=	0.0020
				Adj R-squared	=	0.0018
Total	397101.753	5,494	72.2791687	Root MSE	=	8.4939
abs_res	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
salcalc	-.1316998	.0395127	-3.33	0.001	-.2091604	-.0542392
_cons	13.04327	.2897252	45.02	0.000	12.47529	13.61125

En utilisant seulement les résultats obtenus sous STATA, nous remarquons que la p-value du coefficient est égale à 0,001 qui est inférieur à 0,05 et 0,01 : nous pouvons donc rejeter H_0 aux seuils de 5% et 1%.

Le salaire horaire net (prime incluse) est significatif et il existe une relation significative entre la valeur absolue des résidus et le salaire ; il y a de l'hétéroscédasticité.

Sous H_0 , nous avons : $t^* = \frac{-0,1316998}{0,0395127} \approx -3,33$.

Comme $|-3,33| > 2,58$ et $1,96$, l'hypothèse nulle est rejetée aux seuils de 5% et 1% ; et la conclusion est la même que la précédente, sous STATA.

Deuxième modèle : $|\hat{u}_i| = \alpha + \beta \sqrt{\text{salcalc}_i} + \eta_i$

. reg abs_res sal_sqrt						
Source	SS	df	MS	Number of obs	=	5,495
Model	711.593768	1	711.593768	F(1, 5493)	=	9.86
Residual	396390.159	5,493	72.1627816	Prob > F	=	0.0017
				R-squared	=	0.0018
				Adj R-squared	=	0.0016
Total	397101.753	5,494	72.2791687	Root MSE	=	8.4949
abs_res	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
sal_sqrt	-.6513543	.2074235	-3.14	0.002	-1.057986	-.2447222
_cons	13.80791	.5382883	25.65	0.000	12.75265	14.86317

En utilisant uniquement les résultats obtenus sous STATA, nous constatons que la p-value associée au coefficient est égale à $0,002 < 0,05$ et $0,01$; nous pouvons donc rejeter H_0 aux seuils de 5% et 1%.

La racine du salaire est significative, et il existe une relation significative entre la valeur absolue des résidus et la racine carré du salaire, donc il y a de l'hétéroscédasticité.

Sous H_0 , nous avons : $t^* = -\frac{0,6513543}{0,2074235} \approx -3.140214585 = -3,14$.

Comme $|-3,14| > 2,58$ et $1,96$, l'hypothèse nulle est rejetée aux seuils de 5% et 1% ; et la conclusion est la même que la précédente, sous STATA.

Troisième modèle : $|\hat{u}_i| = \alpha + \beta \frac{1}{\text{salcalc}_i} + \eta_i$

Source	SS	df	MS	Number of obs	=	5,495
Model	300.029036	1	300.029036	F(1, 5493)	=	4.15
Residual	396801.724	5,493	72.2377069	Prob > F	=	0.0416
				R-squared	=	0.0008
				Adj R-squared	=	0.0006
Total	397101.753	5,494	72.2791687	Root MSE	=	8.4993

abs_res	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
sal_inv	2.526473	1.239695	2.04	0.042	.0961791	4.956767
_cons	11.69656	.2530624	46.22	0.000	11.20045	12.19266

En utilisant uniquement les résultats obtenus sous STATA, nous constatons que la p-value associée au coefficient de l'inverse du salaire est égale à 0,042.

0,042 < 0,05 donc nous pouvons rejeter H_0 au seuil de 5%, mais pas au seuil de 1%.

Il existe une relation significative entre la valeur absolue des résidus et l'inverse du salaire et il y a ainsi de l'hétéroscédasticité, au seuil de 5%.

Sous H_0 , nous avons : $t^* = \frac{2,526473}{1,239695} \approx 2,037979503 = 2,04$.

Comme 2,04 > 1,96, mais 2,04 < 2,58, l'hypothèse nulle est rejetée au seuil de 5%, mais pas au seuil de 1% ; et la conclusion est la même que la précédente, sous STATA.

Quatrième modèle : $|\hat{u}_i| = \alpha + \beta \frac{1}{\sqrt{\text{salcalc}_i}} + \eta_i$

. reg abs_res sal_invsqrt						
Source	SS	df	MS	Number of obs	=	5,495
Model	427.471404	1	427.471404	F(1, 5493)	=	5.92
Residual	396674.282	5,493	72.214506	Prob > F	=	0.0150
				R-squared	=	0.0011
				Adj R-squared	=	0.0009
Total	397101.753	5,494	72.2791687	Root MSE	=	8.4979

abs_res	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
sal_invsqrt	2.82123	1.15957	2.43	0.015	.5480125	5.094447
_cons	10.98558	.4946607	22.21	0.000	10.01585	11.95531

En utilisant uniquement les résultats obtenus sous STATA, nous constatons que la p-value associée au coefficient de est égale à 0,015.

0,015 < 0,05 donc nous rejetons H_0 au seuil de 5%, mais pas au seuil de 1%.

Il existe une relation significative entre la valeur absolue des résidus et l'inverse de la racine carré du salaire ; il y a de l'hétéroscédasticité, au seuil de 5%.

Sous H_0 , nous avons : $t^* = \frac{2,82123}{1,15957} \approx 2,432996714 = 2,43$.

Comme 2,43 > 1,96, mais pas supérieur à 2,58, l'hypothèse nulle est rejetée au seuil de 5%, mais pas au seuil de 1% ; et la conclusion est la même que la précédente, sous STATA.

CONCLUSION

En conclusion, l'objectif de notre projet était d'expliquer la durée en emploi à partir :

- des variables de contrôle telles que le salaire et le niveau d'éducation
- ainsi que des variables explicative, telles que le nombre d'entreprise, la catégorie socio-professionnelle, la taille de l'entreprise, et le sexe.

À partir de l'enquête Génération 1998 et après nettoyage, nous avons travaillé sur un échantillon d'environ 5 495 individus.

Les résultats de notre modèle final s'interprètent par rapport à une catégorie de référence : un homme, titulaire du Bac (ou CAP/BEP), employé (ou ouvrier qualifié/non qualifié), toujours en emploi au moment de l'enquête, et n'ayant travaillé que dans une seule entreprise depuis son entrée dans la sphère professionnelle.

Parmi les variables explicatives du modèle, une s'est révélée être non significative : la taille de l'entreprise.

Les autres variables retenues dans le modèle sont significatives.

Le modèle que nous avons construit, nous montre que la durée en emploi d'une personne diplômée d'un CAP/BEP n'est pas significativement différente de celle d'un individu diplômé du Bac.

De même, nous pensions a priori que, plus la catégorie socio-professionnelle d'un individu était élevée, plus ce dernier allait avoir une durée en emploi plus longue.

Les résultats que nous avons obtenu nous ont montré que les différences de durée en emploi ne sont pas significatives entre les employés, ouvriers qualifiés, non qualifiés et les techniciens ; et que les écarts ne sont significatifs qu'entre les cadres et le reste.

De surcroît, le modèle a montré que les variables qui "impactent" le plus la durée en emploi sont celles relatives à la situation professionnelle de l'individu, et ses expériences professionnelles passées, plutôt que les augmentations de salaire ou le niveau d'éducation.

(Notons que le taux de chômage de l'échantillon n'est pas représentatif ; il s'élève à 20.60% ...)

En ce sens, pour répondre à nos a priori sur le salaire et le niveau d'éducation :

- les augmentations de salaire favorisent effectivement la durée en emploi, mais leur impact reste minime, car à une augmentation du salaire horaire net moyen d'un euro (= 1 680€ de salaire net moyen annuel), est associé une durée en emploi plus grande d'un mois et 15 jours (ce qui est relativement peu, **CETERIS PARIBUS**) ;
- les niveaux d'éducation ne témoignent pas non plus de grands écarts de durée en emploi, comme nous le pensions ; les différences de durée en emploi selon le niveau d'éducation, et par rapport à un individu diplômé du Bac (ou CAP/BEP) ne dépassent pas 6 mois (**CETERIS PARIBUS**).

Le modèle, spécifié dans sa forme finale, explique 42,86% des variations de la durée en emploi. Il reste ainsi 57,34% des variations de la durée en emploi qui restent inexpliquées.

Cela met la lumière sur la nécessité d'introduire davantage de variables explicatives.

Cependant, nous nous devons de nuancer ces résultats : malgré certaines hypothèses du modèle qui ne sont pas vérifiées, nous avons décidé de poursuivre l'étude. A l'aune de ce qui précède, nos résultats sont fondamentalement fallacieuses ; les estimateurs sont biaisés, il n'y a pas de relation de causalité, et les variances ne sont pas constantes (la présence d'hétéroscédasticité ne permet pas aux tests de Student et de Fisher d'être aussi efficaces que nous aimerions qu'ils le soient). Les tests que nous avons utilisés ne permettent ainsi pas de définitivement conclure.

Nous aurions pu y remédier si nous avions pu introduire d'autres variables, qui ne sont pas dans le modèle, et qui pourtant sont corrélées aux variables explicatives du modèle et expliquent aussi la durée en emploi.

Ce peut être le cas, par exemple, pour la situation familiale de l'individu (l'individu est-il marié, célibataire, a-t-il un enfant ou plus ?) ou encore la santé de ce dernier (l'individu tombe-t-il régulièrement malade ? s'est-il récemment fait opéré ? présente-t-il des troubles mentaux ?).